21TH TOBIG'S CONFERENCE

GNN - Based Skincare Recommendation System

랭킹을 넘어: 성분과 피부 타입 간의 상호작용 학습을 중심으로

ToBiGraph | 23기 곽은진 문혜원 염승원
24기 서민정 정연우

Background

ToBiGraph x OLIVE YOUNG

최근, 개인화 뷰티 트렌드 확산에 따라
'나의 피부 고민과 특성'을 반영한 솔루션 수요 급증

그러나 기존 플랫폼의 경우 단순 인기 순위(Top-k), 필터링에 의한 추천에 그쳐, 실질적 개인화 적용 불가

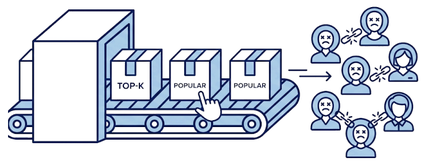

Objective

본 프로젝트는 Graph를 통해 성분-피부타입 간의 관계를 학습하고, 피부 타입별 세그먼트 접근법의 스킨케어 추천 프레임워크를 제안함

Pipeline & Methods

Data Processing

[데이터 수집]

Source 국내 H&B 스토어 '올리브영(Olive Young)' 웹 크롤링

Scale 스킨케어 5대 카테고리의 총 2,416개 상품 데이터 확보

Attributes 상품 기본 정보 (name, category, brand) , 전성분 (Ingredients), 사용자 피부 타입 (Skin Type), 텍스트 리뷰, 평점

[데이터 전처리]

Bias Control 동일 사용자의 과도한 리뷰 데이터 편향을 방지하기 위해, User-Product 쌍당 최대 2개 리뷰로 제한

Quality Filtering ' 유용도' 기준으로 정렬하여 양질의 리뷰 우선 수집

Segmentation 사용자들의 일회성 패턴으로 인한 데이터 희소성 해결을 위해 개별 유저를 피부 타입 세그먼트 단위로 그룹화

Methodology

Graph Neural Network (GNN)

: 그래프 데이터에 적용 가능한 신경망
=> GNN의 목표 : 이웃 노드들 간의 정보를 이용해서 특정 노드를 잘 표현할 수 있는 특징(벡터)을 잘 찾아내는 것

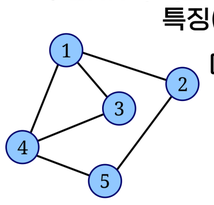

Graph = (V, E)
- Node (V)
  : 그래프의 개별 객체
- Edge (E)
  : 노드 간의 관계나 연결

대표적인 GNN 응용 사례
- Node Classification : 인용 네트워크 분석
- Graph Classification : 화학의 분자 구조 분석
- Link Prediction : 소셜 네트워크 분석 및 추천
  → 사용자 - 아이템 간 잠재적 연결 여부 예측하는 추천시스템

주요 과정

그래프 구성	사용자와 아이템이 각각 노드로 표현되며, 두 노드 간의 상호작용이 엣지로 연결
↓ 메세지 전달	각 노드가 이웃 노드로부터 정보를 보내는 과정
↓ 이웃 집계	이웃 노드들로부터 받은 메시지들을 집계하여 새로운 노드 표현을 만드는 것
↓ 정보 업데이트	집계된 정보를 사용해 노드의 특징을 업데이트

GNN Layer 종류

GCN (Graph Convolutional Network)

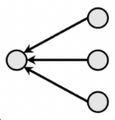

각 노드는 이웃 노드의 정보를 평균하여 새로운 임베딩을 생성하며, 이를 반복하여 학습

GraphSAGE (Graph SAmple and aggreGatE)

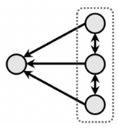

노드의 이웃을 샘플링하여, 그 샘플된 이웃들의 정보를 바탕으로 노드 임베딩을 생성하는 방식

GAT (Graph Attention Network)

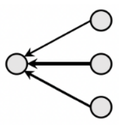

각 이웃 노드의 중요도를 다르게 평가하여, 중요도에 따라 정보를 가중치로 부여하는 어텐션 메커니즘을 사용하는 모델

Pipeline

01 Data Collection

Target: 올리브영(Olive Young) 스킨/토너, 에센스/세럼/앰플, 크림, 로션, 미스트/오일 제품

Source:
- Product: 제품명, 카테고리, 브랜드, 평점
- Ingredients: 화장품 성분
- User Reviews: 피부 타입(건성/지성 등), 리뷰 텍스트, 평점(1~5)

02 Graph Construction

1. Node Definition
- Product Node: 611개 화장품 제품
- SkinType Node: 7개 피부 타입 (건성, 지성, 복합성 등)

2. Edge Definition
- P-P Edge: 성분/리뷰 유사도 기반 KNN 연결(Top-20)
- S-P Edge: 피부 타입별 고평점 제품 연결(Affinity)

03 Feature Engineering

-Ingredient Embedding: 전성분 데이터를 TF-IDF/Count Vector로 변환

-Text Embedding: 리뷰 및 상품 설명의 핵심 키워드를 Sentence Embedding(SBERT)으로 변환

-ID Mapping: User ID, Product ID, SkinType을 고유 정수 인덱스(0~N)로 매핑

04 Model Training

Track A. Single-Node LightGCN
- 모델 구조: Homogeneous Graph (Product Only)
- 입력 피처: ID Emb + Ingredient Vec + Text Vec 융합
- Backbone: LightGCN
- 사용자 선호 제품과 가장 유사한 제품 탐색

Track B. Heterogeneous GNN
- 모델 구조: Heterogeneous Graph (Product+SkinType)
- 입력 피처: Product Features + SkinType Embedding
- Backbone: HeteroConv (SAGEConv 기반)
- 피부 타입과 제품 간의 연결 확률 예측

05 Demo Service

최종 사용자에게 시각적인 추천 결과를 제공하는 웹 인터페이스

1. User Input
본인의 피부 타입 선택 (예: "수부지")
과거에 잘 맞았던 인생템(Seed Item) 1개 검색 및 선택

2. Processing
선택된 제품의 GNN 임베딩 추출 및 전체 제품과 거리 계산
피부 타입별 적합도 점수와 결합하여 랭킹 산출

3. Output Display
Best Pick: 최적 추천 제품 1개 상세 정보 (성분 하이라이트)
Top-K List: 추천 제품 4~5개 카드 뷰 제공

Results

Modeling

1. Homogeneous GNN - LightGCN

Graph Construction

Node : Product

Node Features
- Product ID: 64dim Embedding
- Category / Brand: 64dim Embedding
- Ingredients: 평점 기반 피부타입별 성분 선호도
- Review Text: TF-IDF + SVD [128dim]

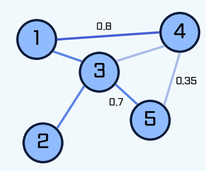

Edge
- E = {(i,j) | cosine_sim(i,j) ≥ 0.3}
- Weight: 유사도 값 (0.3 ~ 1.0)
- 7개 피부타입 평균 선호도 기반

Feature Fusion : Concat + Linear
- Concat : [ID | Brand | Category | Ing | Text]
- Linear Projection → 256d Initial Embedding

Model Architecture : Homo-LightGCN

Input	- Product: 5개 노드 피처 - Graph: Product-Product 성분 유사도
GNN	- Feature Fusion : Concat → 256dim - 3-layer LightGCN • Graph Convolution × 3 • Weighted Aggregation (edge weight) • Mean Pooling (4 layers)
Output	- 256-dim embeddings - 7 Skintype Logits (Classification)

Training (Multi-label Classification)

Hybrid Loss Function = BCE + BPR
*BCE (Classification), BPR (Ranking)

2. Heterogeneous GNN - GraphSAGE

$$Affinity(s,p) = \frac{\#reviews(p,s)}{\#reviews(p)}$$

Data Preprocessing & Feature Engineering

Node Features

Product(Xitem) $X_{item} = [X_{ing} \mid X_{rev} \mid X_{cat} \mid X_{rating} \mid X_{brand}]$
- Ingredients(TF-IDF)
- Review Text(TF-IDF, rating-weighted)
- Category/ Brand(One-hot)
- Product Rating(normalized)

Skin Type
- Learnable Embedding
- Extracted&Normalized from reviews

Heterogeneous Graph Design

Target Edge
- SkinType -> Product
- Review-based Affinity Score
- Unidirectional (Positive Edges)

Support Edge
- Product ↔ Product
- Ingredient (0.6) + Review (0.4)
- Bidirectional

Model Architecture: Hetero-GraphSAGE

Input	- Product: rich feature → MLP - SkinType: index → Embedding
GNN	- 2-layer Hetero GraphSAGE - Relations: SkinType → Product (target) Product ↔ Product (support)
Output	- 256-dim embeddings - Inner product = recommendation score

$$Score(p) = \beta \cdot score_{seed}(q,p) + (1-\beta) \cdot score_{skin}(s,p)$$

Training (Link Prediction)

Positive Samples:
- Observed SkinType → Product edges

Negative Sampling:
- Random negatives (50%)
- Hard negatives (50%)

Loss: Binary Cross Entropy

Results

Model	AUC	AP
Homogeneous GNN - LightGCN	0.8506	0.9368
Heterogeneous GNN - GraphSAGE	0.8381	0.7621

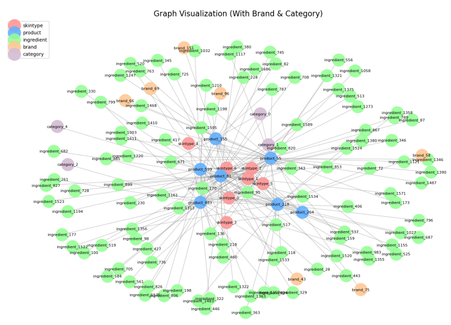

1. 사용자 희소성 문제를 해결하기 위한 피부 타입 세그먼트 기반 추천 프레임워크 제안
2. 성분-제품-피부타입 관계를 반영한 이종 그래프 기반 추천 모델 설계
3. 리뷰 및 전성분 TF-IDF 기반 선호 features 구성
4. 사용자 평점 편향을 고려한 샘플링 및 loss 조정을 통한 노이즈 완화

Contribution

23기 곽은진	23기 문혜원	23기 염승원	24기 서민정	24기 정연우
• Crawling • Heterogeneous Graph modeling	• Crawling • Heterogeneous Graph modeling • Prototype	• Crawling • Heterogeneous Graph modeling	• Crawling • Homogeneous Graph modeling	• Crawling • Homogeneous Graph modeling